

Relatório do Laboratório 3 - Otimização com Métodos de Busca Local

1 Breve Explicação em Alto Nível da Implementação

1.1 Descida do Gradiente

Esse método de busca consiste em avaliar pontos na direção contrária à do gradiente, ou seja, na direção de maior decrescimento da função. Define-se um custo inicial (θ_0) a partir do qual se inicia a busca. A condição de parada, para essa implementação, é definida a partir do número de iterações, que deve ser menor do que o número máximo de iterações, e de uma tolerância, de forma que se finalizam as iterações caso o custo do θ atual seja menor do que ela. Atribui-se um novo θ_k segundo a Equação 1:

$$\theta_{k+1} = \theta_k - \alpha \frac{\partial J(\theta)}{\partial \theta} \quad (1)$$

O parâmetro α é definido por tentativa e erro e a função de custo J é obtida a partir da modelagem física do problema. No código, o gradiente é obtido a partir da função `gradient_function`.

1.2 *Hill Climbing*

Esse método de busca consiste em visitar os pontos vizinhos ao θ atual e avaliar qual deles é o mais ótimo. Na implementação do código, adotou-se a estratégia 8-conectada para obtenção dos vizinhos, conforme a função `neighbors`, que calcula todos os 8 vizinhos simetricamente dispostos em um círculo de raio Δ em torno do θ atual. Na função `hill_climbing`, o critério de parada é o mesmo do método da Descida do Gradiente. Para cada iteração, é inicialmente atribuído o melhor θ (`best`) como `None` e lhe é atribuído o custo infinito. A iteração consiste em verificar se há algum vizinho cujo custo seja menor do que o do `best`: em caso positivo, o novo `neighbor` assume a posição de `best` e a comparação é feita com o custo desse `neighbor`. Caso o `theta` atual tenha o menor custo dentre seus vizinhos, encontrou-se o mínimo local e o `loop` é finalizado. Caso contrário, o `theta` atual assume a posição do melhor dos vizinhos e prossegue-se o `loop`.

1.3 *Simulated Annealing*

Esse método é semelhante ao algoritmo *Hill Climbing*, sendo um método metaheurístico para determinar o mínimo global da função de custo, evitando que “fique preso” a mínimos locais. A busca é regulada por uma “temperatura”, que define com que “energia” a busca é feita. Essa temperatura é calculada conforme um *scheduling*, que, na implementação do código, é definida pela função `scheduling`, cujo valor diminui ao longo das iterações, segundo a Equação 2.

$$T(i) = \frac{T_0}{1 + \beta i} \quad (2)$$

Em um processo estocástico, a cada iteração define-se um novo θ a partir da função **random_neighbor**. Define-se a diferença de custo (**deltaE**) de forma a avaliar se o custo do vizinho é menor do que o custo do θ atual. Em caso positivo, atribui-se a θ o estado **neighbor** e prossegue-se para a próxima iteração. Em caso contrário, utiliza-se uma função de probabilidade em função da temperatura para se determinar um novo estado. A condição de parada é idêntica às condições dos dois últimos algoritmos, acrescida da condição de $T \geq 0$.

2 Figuras Comprovando Funcionamento do Código

2.1 Descida do Gradiente




Figura 1: Trajetória criada utilizando-se o método Descida do Gradiente.

2.2 *Hill Climbing*




Figura 2: Trajetória criada utilizando-se o método *Hill Climbing*.

2.3 *Simulated Annealing*




Figura 3: Trajetória criada utilizando-se o método *Simulated Annealing*.

3 Comparação entre os métodos




Figura 4: Comparação entre as trajetórias de otimização dos três métodos de busca.




Figura 5: Comparação entre as curvas de regressão linear dos três métodos de busca e o método dos mínimos quadrados, além da série de dados.

Tabela 1 com a comparação dos parâmetros da regressão linear obtidos pelos métodos de otimização.

Tabela 1: Parâmetros da regressão linear obtidos pelos métodos de otimização.

Método	v_0	f
MMQ	0.433373	-0.101021
Descida do gradiente	0.433371	-0.101018
<i>Hill climbing</i>	0.433411	-0.101196
<i>Simulated annealing</i>	0.433977	-0.101345