

Relatório do Laboratório 7 - *Imitation Learning* com Keras

1 Breve Explicação em Alto Nível da Implementação

O objetivo deste laboratório foi implementar uma rede neural profunda por meio da biblioteca Keras do framework Tensorflow da linguagem Python. Em especial, implementou-se uma rede neural com o objetivo de aprender o movimento de um robô humanoide, por meio do *imitation learning*. A rede neural foi composta por 3 camadas: a de entrada, composta por 75 neurônios e com função de ativação Leaky ReLU ($\alpha = 0.01$), uma escondida, composta por 50 neurônios e com função de ativação Leaky ReLU ($\alpha = 0.01$) e a de saída, com 20 neurônios e função de ativação linear. A *loss* utilizado foi a função de erro quadrático. Não foram usados mini-batches nem regularização e o treinamento foi feito com 30000 épocas e foi utilizado o algoritmo de otimização de Adam. O dataset consiste de dados da posição de 20 juntas do robô humanoide em um movimento de ciclo.

2 Figuras Comprovando Funcionamento do Código

2.1 Função de Classificação sum_gt_zeros




Figura 1: Dataset gerado da função de classificação sum_gt_zeros para teste da rede neural sem regularização L_2 .




Figura 2: Região de classificação obtida pela rede neural para a função sum_gt_zeros sem regularização L_2 .




Figura 3: Gráfico de convergência da função do custo para a função sum_gt_zeros sem regularização L_2 .




Figura 4: Dataset gerado da função de classificação sum_gt_zeros para teste da rede neural com parâmetro $\lambda = 0.002$ da regularização L_2 .




Figura 5: Região de classificação obtida pela rede neural para a função sum_gt_zeros com parâmetro $\lambda = 0.002$ da regularização L_2 .




Figura 6: Gráfico de convergência da função do custo para a função *sum_gt_zeros* com parâmetro $\lambda = 0.002$ da regularização L_2 .

2.2 Função de Classificação *XOR*




Figura 7: Dataset gerado da função de classificação *XOR* para teste da rede neural sem regularização L_2 .




Figura 8: Região de classificação obtida pela rede neural para a função XOR sem regularização L_2 .




Figura 9: Gráfico de convergência da função do custo para a função XOR sem regularização L_2 .




Figura 10: Dataset gerado da função de classificação XOR para teste da rede neural com parâmetro $\lambda = 0.002$ da regularização L_2 .




Figura 11: Região de classificação obtida pela rede neural para a função XOR com parâmetro $\lambda = 0.002$ da regularização L_2 .




Figura 12: Gráfico de convergência da função do custo para a função sum_gt_zeros com parâmetro $\lambda = 0.002$ da regularização L_2 .

2.3 Imitation Learning




Figura 13: Movimento de arfagem da junta do tornozelo direito do robô humanoide obtido pela rede neural, em laranja, e o original, em azul.




Figura 14: Movimento de rolamento da junta do tornozelo direito do robô humanoide obtido pela rede neural, em laranja, e o original, em azul.




Figura 15: Movimento de arfagem da junta direita do quadril do robô humanoide obtido pela rede neural, em laranja, e o original, em azul.




Figura 16: Movimento de rolamento da junta direita do quadril do robô humanoide obtido pela rede neural, em laranja, e o original, em azul.




Figura 17: Movimento de arfagem da junta do joelho direito do robô humanoide obtido pela rede neural, em laranja, e o original, em azul.

3 Discussões

Em relação ao desempenho do teste da rede neural na função de classificação *sum_gt_zeros*, nota-se que o overfitting não é um problema que influencia tanto o aprendizado para essa função, pois o resultado obtido com e sem regularização L_2 são idênticos, conforme as Figuras 2 e 5. No entanto, em relação à função de classificação *XOR*, o overfitting pode ser um problema, pois o desempenho utilizando a regularização L_2 foi significativamente melhor, o que é evidenciado comparando-se as fronteiras das regiões nas Figuras 8 e 11 e os gráficos de convergência das funções de custo (Fig. 9 e 12, em que se nota que a convergência foi afetada pelo termo da regularização). Em relação ao imitation learning dos movimentos das juntas do robô humanoide, em geral, obteve-se um desempenho satisfatório levando-se em consideração a rede neural implementada, tendo melhores desempenhos nas curvas originais mais suaves (como nas Figuras 13 e 15) em comparação a curvas mais ruidosas (como na Figura 16), indicando que não houve um overfitting excessivo.