

Relatório do Laboratório 10 - Programação Dinâmica

1 Breve Explicação em Alto Nível da Implementação

O objetivo deste relatório é analisar a implementação de programação dinâmica para analisar políticas e obter a política ótima de um Processo Decisório de Markov (MDP). Nesse caso, o MDP consiste de um tabuleiro formado por um *grid* $n \times n$ em que em cada célula são permitidas cinco ações: *stop* (S), *up* (U), *right* (R), *down* (D) e *left* (L). A ação de *stop* tem probabilidade 1 de ocorrer e as outras ações têm probabilidade de execução p_c , em que, quando a ação não é executada, todas as ações de direção têm probabilidade $\frac{1-p_c}{4}$ de ocorrer. O *grid* contém obstáculos, células as quais não é possível ocupar, além das barreiras do *grid*. Ainda, o MDP tem fator de desconto γ e recompensa -1 para cada *timestep* em que a célula do agente não é a célula objetivo, que é única e agente recebe recompensa 0 por nela estar. Note que o MDP em questão tem um modelo matemático conhecido.

1.1 Avaliação de Política

A avaliação da política π consiste em obter a função de valor para cada estado mantendo-se fixa a política. A função valor para um estado s é obtido a partir da Equação de Bellman de Expectativa, exibida pela Equação 1, em que em cada iteração analisa-se a ação possível a por meio de sua recompensa r e analisam-se os próximos estados s' por meio da probabilidade de transição p , definida pelo modelo da MDP.

$$v_\pi(s) = \sum_{a \in A} \pi(a|s) \left(r(s|a) + \gamma \sum_{s' \in S} p(s'|s, a) v_\pi(s') \right) \quad (1)$$

A implementação de avaliação de política consiste em resolver iterativamente o sistema de equações dado pela Equação 1 para cada estado, obtendo-se $v_{k+1}(s)$ a partir de $v_k(s')$, utilizando-se o método de Gauss-Jacobi em uma atualização síncrona. O algoritmo converge para a função valor da política $v_\pi(s)$.

1.2 Iteração de Valor

A iteração de valor consiste em encontrar a função de valor ótima $v_*(s)$ a partir da Equação de Bellman de Otimalidade, dada pela Equação 2. Para cada estado, escolhe-se a ação que maximiza a função valor.

$$v_{k+1}(s) = \max_{a \in A} \left(r(s, a) + \gamma \sum_{s' \in S} p(s'|s, a) v_k(s') \right) \quad (2)$$

A implementação consiste em resolver o sistema linear iterativamente. O algoritmo converge para $v_*(s)$. A política ótima pode ser encontrada a partir da função de valor ótima por meio do algoritmo “guloso” ($\pi'(s) = \text{greedy}(v_\pi(s))$), dado pela Equação 3.

$$\pi'(s) = \underset{a \in A}{\operatorname{argmax}} \left(r(s, a) + \gamma \sum_{s' \in S} p(s'|s, a) v_\pi(s') \right) \quad (3)$$

1.3 Iteração de Política

A iteração de política consiste em avaliar iterativamente uma política e atualizá-la de forma gulosa em relação $v_k(s)$, a partir da Equação 3. O algoritmo termina em uma condição de parada, dada pelo número de iterações ou com um valor mínimo para a diferença da função valor de iterações consecutivas. O algoritmo converge para a política ótima.

2 Tabelas Comprovando Funcionamento do Código

2.1 Caso $p_c = 1,0$ e $\gamma = 1,0$

2.1.1 Avaliação de Política

```
Evaluating random policy, except for the goal state, where policy always executes stop:
Value function:
[ -384.09, -382.73, -381.19, *, -339.93, -339.93]
[ -380.45, -377.91, -374.65, *, -334.92, -334.93]
[ -374.34, -368.82, -359.85, -344.88, -324.92, -324.93]
[ -368.76, -358.18, -346.03, *, -289.95, -309.94]
[ *, -344.12, -315.05, -250.02, -229.99, * ]
[ -359.12, -354.12, *, -200.01, -145.00, 0.00]
Policy:
[ SURDL , SURDL , SURDL , * , SURDL , SURDL ]
[ SURDL , SURDL , SURDL , * , SURDL , SURDL ]
[ SURDL , SURDL , SURDL , SURDL , SURDL , SURDL ]
[ SURDL , SURDL , SURDL , * , SURDL , SURDL ]
[ * , SURDL , SURDL , SURDL , SURDL , * ]
[ SURDL , SURDL , * , SURDL , SURDL , S ]
```

Figura 1: Tabela do *grid* com a função valor de avaliação de uma política aleatória para $p_c = 1,0$ e $\gamma = 1,0$.

2.1.2 Iteração de Valor

```
Value iteration:
Value function:
[  -10.00,   -9.00,   -8.00,   *   ,   -6.00,   -7.00]
[  -9.00,   -8.00,   -7.00,   *   ,   -5.00,   -6.00]
[  -8.00,   -7.00,   -6.00,  -5.00,   -4.00,   -5.00]
[  -7.00,   -6.00,   -5.00,   *   ,   -3.00,   -4.00]
[   *   ,   -5.00,   -4.00,  -3.00,   -2.00,   *   ]
[  -7.00,   -6.00,   *   ,   -2.00,   -1.00,   0.00]
Policy:
[   RD   ,   RD   ,   D   ,   *   ,   D   ,   DL   ]
[   RD   ,   RD   ,   D   ,   *   ,   D   ,   DL   ]
[   RD   ,   RD   ,   RD   ,   R   ,   D   ,   DL   ]
[   R    ,   RD   ,   D   ,   *   ,   D   ,   L    ]
[   *    ,   R    ,   R    ,   RD  ,   D   ,   *   ]
[   R    ,   U    ,   *    ,   R    ,   R    ,   SURD ]
```

Figura 2: Tabela do *grid* com a função valor e política ótimas a partir da iteração de valor para $p_c = 1,0$ e $\gamma = 1,0$.

2.1.3 Iteração de Política

```
Policy iteration:
Value function:
[  -10.00,   -9.00,   -8.00,   *   ,   -6.00,   -7.00]
[  -9.00,   -8.00,   -7.00,   *   ,   -5.00,   -6.00]
[  -8.00,   -7.00,   -6.00,  -5.00,   -4.00,   -5.00]
[  -7.00,   -6.00,   -5.00,   *   ,   -3.00,   -4.00]
[   *   ,   -5.00,   -4.00,  -3.00,   -2.00,   *   ]
[  -7.00,   -6.00,   *   ,   -2.00,   -1.00,   0.00]
Policy:
[   RD   ,   RD   ,   D   ,   *   ,   D   ,   DL   ]
[   RD   ,   RD   ,   D   ,   *   ,   D   ,   DL   ]
[   RD   ,   RD   ,   RD   ,   R   ,   D   ,   DL   ]
[   R    ,   RD   ,   D   ,   *   ,   D   ,   L    ]
[   *    ,   R    ,   R    ,   RD  ,   D   ,   *   ]
[   R    ,   U    ,   *    ,   R    ,   R    ,   SURD ]
```

Figura 3: Tabela do *grid* com a função valor e política ótimas a partir da iteração de política para $p_c = 1,0$ e $\gamma = 1,0$.

2.2 Caso $p_c = 0,8$ e $\gamma = 0,98$

2.2.1 Avaliação de Política

```
Evaluating random policy, except for the goal state, where policy always executes stop:
Value function:
[ -47.19, -47.11, -47.01, * , -45.13, -45.15]
[ -46.97, -46.81, -46.60, * , -44.58, -44.65]
[ -46.58, -46.21, -45.62, -44.79, -43.40, -43.63]
[ -46.20, -45.41, -44.42, * , -39.87, -42.17]
[ * , -44.31, -41.64, -35.28, -32.96, * ]
[ -45.73, -45.28, * , -29.68, -21.88, 0.00]
Policy:
[ SURDL , SURDL , SURDL , * , SURDL , SURDL ]
[ SURDL , SURDL , SURDL , * , SURDL , SURDL ]
[ SURDL , SURDL , SURDL , SURDL , SURDL , SURDL ]
[ SURDL , SURDL , SURDL , * , SURDL , SURDL ]
[ * , SURDL , SURDL , SURDL , SURDL , * ]
[ SURDL , SURDL , * , SURDL , SURDL , S ]
```

Figura 4: Tabela do *grid* com a função valor de avaliação de uma política aleatória para $p_c = 0,8$ e $\gamma = 0,98$.

2.2.2 Iteração de Valor

```
Value iteration:
Value function:
[ -11.65, -10.78, -9.86, * , -7.79, -8.53]
[ -10.72, -9.78, -8.78, * , -6.67, -7.52]
[ -9.72, -8.70, -7.59, -6.61, -5.44, -6.42]
[ -8.70, -7.58, -6.43, * , -4.09, -5.30]
[ * , -6.43, -5.17, -3.87, -2.76, * ]
[ -8.63, -7.58, * , -2.69, -1.40, 0.00]
Policy:
[ D , D , D , * , D , D ]
[ D , D , D , * , D , D ]
[ RD , D , D , R , D , D ]
[ R , RD , D , * , D , L ]
[ * , R , R , D , D , * ]
[ R , U , * , R , R , S ]
```

Figura 5: Tabela do *grid* com a função valor e política ótimas a partir da iteração de valor para $p_c = 0,8$ e $\gamma = 0,98$.

2.2.3 Iteração de Política

```

Policy iteration:
Value function:
[  -11.65,  -10.78,  -9.86,  *   ,  -7.79,  -8.53]
[  -10.72,  -9.78,  -8.78,  *   ,  -6.67,  -7.52]
[   -9.72,  -8.70,  -7.59, -6.61,  -5.44,  -6.42]
[   -8.70,  -7.58,  -6.43,  *   ,  -4.09,  -5.30]
[    *   ,  -6.43,  -5.17, -3.87,  -2.76,  *   ]
[   -8.63,  -7.58,  *   ,  -2.69,  -1.40,  0.00]
Policy:
[    D   ,    D   ,    D   ,    *   ,    D   ,    D   ]
[    D   ,    D   ,    D   ,    *   ,    D   ,    D   ]
[    R   ,    D   ,    D   ,    R   ,    D   ,    D   ]
[    R   ,    D   ,    D   ,    *   ,    D   ,    L   ]
[    *   ,    R   ,    R   ,    D   ,    D   ,    *   ]
[    R   ,    U   ,    *   ,    R   ,    R   ,    S   ]

```

Figura 6: Tabela do *grid* com a função valor e política ótimas a partir da iteração de política para $p_c = 0,8$ e $\gamma = 0,98$.

3 Discussão dos Resultados

A implementação e os testes dos algoritmos de programação dinâmica forneceram uma visão clara sobre a resolução de Processos Decisórios de Markov (MDPs) com modelo conhecido. A análise dos resultados, tanto para o ambiente determinístico quanto para o estocástico, permite extrair conclusões importantes sobre o comportamento dos métodos e a natureza das políticas ótimas resultantes.

Primeiramente, é fundamental observar que tanto a Iteração de Valor quanto a Iteração de Política convergiram para a mesma função de valor ótima e, conseqüentemente, para a mesma política ótima em ambos os cenários testados ($p_c = 1,0$ e $p_c = 0,8$). Este resultado era esperado e valida a correção teórica e prática de ambas as implementações, pois os dois algoritmos são garantidos a encontrar a solução ótima. A principal diferença entre eles reside na sua abordagem computacional: a Iteração de Política alterna entre uma avaliação completa da política atual e um passo de melhoria gulosa, enquanto a Iteração de Valor funde essas duas etapas em uma única equação de atualização (a equação de Bellman de Otimalidade). Na prática, a Iteração de Política pode convergir em menos iterações, mas cada iteração é mais custosa. A escolha entre os dois métodos depende, portanto, das características específicas do problema, como o número de estados e ações.

Analisando o caso determinístico ($p_c = 1,0$, $\gamma = 1,0$), os resultados são bastante intuitivos. A função de valor ótima, conforme exibida na Figura 2 e na Figura 3, apresenta valores inteiros negativos. Isso ocorre porque, com um fator de desconto $\gamma = 1$ e uma recompensa de -1 por passo, o valor de um estado é exatamente o negativo do número de passos no caminho mais curto até o estado objetivo. A política ótima reflete essa realidade, sendo direta e “agressiva”, traçando

o caminho geometricamente mais curto sem hesitar em se mover adjacente a obstáculos, visto que não há risco de uma ação falhar e resultar em uma penalidade de tempo.

O caso estocástico ($p_c = 0,8$, $\gamma = 0,98$) revela um comportamento muito mais rico e interessante. A introdução da incerteza (20% de chance de uma ação aleatória ocorrer) e do fator de desconto ($\gamma < 1$) altera fundamentalmente a natureza da política ótima. A função de valor não é mais uma simples contagem de passos, e a política resultante, exibida nas Figuras 5 e 6, torna-se visivelmente mais “cautelosa”. O agente agora evita trajetórias que, embora geometricamente mais curtas, o colocam em risco. Por exemplo, ele pode preferir um caminho que o mantenha mais centralizado no corredor em vez de um que “raspa” a parede de um obstáculo. Isso ocorre porque o custo esperado de uma ação que beira um obstáculo é maior, pois a probabilidade de uma ação aleatória resultar em uma colisão (e, portanto, em perda de tempo) é significativa. A política ótima não busca mais o caminho mais curto, mas sim o caminho que minimiza a soma descontada de recompensas negativas a longo prazo, efetivamente buscando o caminho mais seguro e eficiente em termos de expectativa.

Em suma, os experimentos demonstram com sucesso a capacidade dos algoritmos de programação dinâmica em resolver MDPs e ilustram de forma eficaz o impacto da estocasticidade na formulação de uma estratégia ótima, forçando a transição de um planejamento puramente geométrico para um planejamento robusto à incerteza.